

Verantwoorde Inzet van Artificial Intelligence



Joris Heemskerk

AI Master Student
Universiteit van Utrecht



Prof. dr. Bas van Gils

Managing partner @ Strategy Alliance
Professor @ Antwerp Management School

Abstract

AI is niet meer weg te denken uit het moderne bedrijfsleven, maar de inzet ervan brengt ook serieuze risico's met zich mee. In dit white paper verkennen we wat verantwoorde AI-inzet inhoudt, en wat dat concreet betekent voor organisaties die overwegen een AI-systeem te introduceren. We doen dit aan de hand van vijf domeinen uit het onderzoeksveld Responsible AI: Privacy & Data Protection, Accountability & Governance, Fairness, Transparency & Explainability en Human Oversight. Per domein beschrijven we de relevante risico's en de concrete stappen die organisaties nu al kunnen zetten.

Om de theorie te gronden in de praktijk, voerden we een coöperatiesessie uit met een groep IT-professionals. Aan de hand van een concrete casus, een pakketbezorgingsbedrijf dat kiest tussen een regel-gebaseerde chatbot en een LLM, onderzochten we hoe professionals de afwegingen rond verantwoorde AI maken. De resultaten onthullen een opvallende spanning: wat professionals verstandig achten en wat zij verwachten dat klanten willen, loopt merkbaar uiteen. Die spanning vormt de rode draad van dit white paper. De conclusie is dat organisaties niet moeten kiezen voor de meest geavanceerde technologie, maar voor de technologie die het beste past bij hun specifieke context, risicobereidheid en verantwoordelijkheden.

1. Inleiding

Het lijkt wel alsof iedereen het tegenwoordig heeft over kunstmatige intelligentie (AI): software-leveranciers streven ernaar hun tools "AI-gedreven" te maken, de apps op hun telefoon worden als verouderd beschouwd als ze geen AI-component bevatten, studenten gebruiken *agentische* AI om (een deel van) hun studiewerk af te handelen, en managers sporen hun medewerkers aan om maximale waarde uit AI te halen om de productiviteit te verhogen. Dit is interessant, want AI is niet zo nieuw als je misschien denkt.

In een recente presentatie schetste prof. Guizzardi een ruwe tijdlijn van de ontwikkeling van AI (Guizzardi, 2024). De discussie over AI begon, ruwweg, in de jaren vijftig met de introductie van *Turings imitatiespel* (zie bijv. https://en.wikipedia.org/wiki/Turing_test). In de jaren vijftig vond de *Dartmouth-conferentie* plaats, die de eerste "AI-zomer" markeerde.

Een van de eerste min of meer AI-achtige tools die redelijk breed beschikbaar kwam, was ELIZA (zie bijv. <https://en.wikipedia.org/wiki/ELIZA>). Dit was medio de jaren zestig en kan worden beschouwd als de eerste chatbot. Op dat moment eindigde de eerste AI-zomer en brak de lange "AI-winter" aan. In de jaren tachtig ontstonden nieuwe computerparadigma's (bijv. Prolog) die de interesse in AI kort nieuw leven inbliezen. Daarna nam de interesse opnieuw af, totdat nieuwe ontwikkelingen (data, rekenkracht,

geheugen) medio de jaren negentig voor hernieuwde belangstelling zorgden. De “opkomst van ChatGPT” (en vergelijkbare LLM’s) bezegelde de zaak. AI is gekomen om te blijven.

Een deel van het vraagstuk schuilt in de vraag: wat bedoelen we eigenlijk met de term AI? Een vluchtige verkenning van de beschikbare literatuur suggereert dat er definities in overvloed zijn. Als we de lijn volgen die wordt gepresenteerd in de eerdergenoemde lezing van Guizzardi, kunnen we stellen dat *AI-systemen systemen zijn die zich intelligent gedragen – voor een bepaalde definitie van intelligentie*. Daar zit natuurlijk de kern van het debat: wat is intelligentie?

Men kan betogen dat systemen intelligent zijn of zich intelligent gedragen wanneer ze de Turing-test doorstaan. Dat wil zeggen: wanneer we voor een specifieke taak geen onderscheid kunnen maken tussen een menselijke actor en een computeractor. Veel systemen zouden deze test doorstaan voor kleine, beperkte taken (d.w.z. Ik kan geen onderscheid maken tussen mijn accountant en boekhoudsoftware als het gaat om het opstellen van een balans). Een uitgebreidere definitie van intelligentie zou zijn: *weten wat je moet doen als je niet weet wat je moet doen* (Piaget, 2005). Aanzienlijk minder systemen zouden deze test doorstaan.

Afhankelijk van de manier waarop intelligentie in systemen wordt “geïmplementeerd”, kunnen we verschillende typen systemen onderscheiden. Een eerste onderscheid is dat tussen systemen die van nature *deterministisch* zijn (d.w.z. ze gebruiken complexe regelsets, maar genereren altijd dezelfde uitvoer voor een gegeven set invoer) versus systemen die *statistische* methoden gebruiken om van data te leren. Binnen deze klasse van machine learning kunnen we verder inzoomen op specifiekere vormen, zoals *deep learning* (waarbij neurale netwerken worden gebruikt om het menselijk brein na te bootsen), *GenAI* (systemen die in staat zijn om uitvoer te genereren) en *LLM’s* (GenAI-systemen die tokenvoorspelling gebruiken om tekst te genereren). De exacte hiërarchie van typen is hier niet zo relevant, maar het feit dat er meer achter AI schuilt dan op het eerste gezicht lijkt, is zeker relevant.

2. Verantwoorde AI

Juist die veelvormigheid van AI maakt de vraag naar verantwoord gebruik zo urgent. Een deterministisch systeem dat altijd dezelfde output geeft, laat zich relatief goed controleren.

Maar wat doe je met een LLM dat, afhankelijk van hoe een vraag is gesteld, tot wezenlijk andere antwoorden kan komen? Organisaties gebruiken AI steeds vaker, maar dat brengt ook risico's met zich mee. Het onderzoeksgebied Responsible AI (Verantwoorde AI) richt zich op het beheersen van deze risico's en het verantwoord inzetten van AI-systemen. Hierbij is *ethiek* van groot belang, voornamelijk met betrekking tot de morele afwegingen die hiervoor nodig zijn (zie o.a. Liu and Zheng (2022) en Dignum (2019)).

Responsible AI is op verschillende manieren onder te verdelen (Barredo Arrieta et al., 2020; European Commission et al., 2019; Radanliev, 2025). We onderscheiden vijf categorieën die elk een andere uitdaging adresseren: *Privacy & Data protection, Accountability & Governance, Fairness, Transparency & Explainability, en Human Oversight*. Hieronder gaan we per categorie in op de uitdagingen en de concrete stappen die nu al genomen kunnen worden richting een meer verantwoorde inzet van AI.

2.1 Privacy & Data Protection

Wanneer een organisatie een AI-systeem inzet dat met klantgegevens werkt, ontstaat meteen de vraag: wie ziet wat, en wat gebeurt er met die data? *Privacy & Data Protection* richt zich op het beschermen en beveiligen van gevoelige gegevens van bedrijven en gebruikers. Een risico is dat gebruikers via de AI-chatbot van een bedrijf gevoelige informatie uit de trainingsdata kunnen opvragen. Een ander risico is dat een kwaadaardige actor de AI-chatbot van buitenaf kan beïnvloeden, bijvoorbeeld om klanten weg te drijven of verkeerde informatie te verspreiden.

Om het risico op dit soort aanvallen te beperken, passen bedrijven verschillende *filtertechnieken* toe die proberen te herkennen of de input van een gebruiker (prompt) ongewenst is. Momenteel zijn technieken als *prompt-injectie* (het aanpassen van de input voor een AI-chatbot zodat deze beveiligingen omzeilt) echter niet volledig te voorkomen. Het blijft mogelijk voor kwaadwillenden om door de filtering te komen (Gulyamov et al., 2026; Lee et al., 2025).

Toch zijn er concrete stappen die bepaalde risico's aanzienlijk kunnen beperken. Een AI-chatbot kan nooit gevoelige data prijsgeven als die data simpelweg geen onderdeel vormt van de trainingsdata of niet toegankelijk is voor het systeem. Het is daarom aan te raden selectief te zijn met welke data voor training wordt gebruikt. Verder is het gebruikelijk om klantinteracties in

de loop van de tijd te gebruiken voor het trainen van een volgende versie van het systeem. Als dat niet zorgvuldig gebeurt, kan het systeem onbedoeld persoonlijke of anderszins gevoelige informatie gebruiken/leren. Ook hiervoor geldt: hanteer een expliciete *selectieprocedure* waarbij persoonlijk identificeerbare informatie voorafgaand aan training wordt gefilterd. Meer in het algemeen ligt de primaire verdediging momenteel niet in het volledig voorkomen van prompt-injecties zelf (dat blijkt te moeilijk) maar in het voorkomen dat een succesvolle injectie ook daadwerkelijk ongewenste data kan blootleggen.

2.2 Accountability & Governance

Als het misgaat met een AI-systeem (en dat gaat het vroeg of laat) wordt onvermijdelijk de vraag gesteld: wie is er eigenlijk verantwoordelijk? *Accountability & Governance* betreft precies die vraag: wie is verantwoordelijk voor de beslissingen en gevolgen van een AI-systeem, en welke regels en structuren gelden daarvoor? Dit is inherent complex, omdat AI-systemen opereren op het snijvlak van techniek, recht en ethiek. Wie is aansprakelijk wanneer een AI-chatbot onjuist medisch advies geeft: de gebruiker, de ontwikkelaar, of de organisatie die het systeem inzet? En wie bezit de auteursrechten op een afbeelding die volledig door een generatief AI-systeem is gegenereerd?

De meest relevante wetgeving op dit gebied is de EU AI Act (European Parliament and Council of the European Union, 2024), het eerste uitgebreide juridische kader voor AI ter wereld. De verordening hanteert een *risicogebaseerde classificatie*: van verboden systemen, zoals AI die mensen manipuleert via subliminale technieken, tot hoog-risico systemen, algemeen inzetbare systemen en niet-hoog-risico toepassingen. Voor hoog-risico systemen, waaronder AI ingezet bij werving, krediet-verlening of strafrechtelijke besluitvorming, gelden strenge eisen ten aanzien van transparantie, databeheer en menselijk toezicht. De wet is sinds augustus 2024 van kracht en wordt gefaseerd tot en met 2027 volledig van toepassing.

Concreet houdt dit voor organisaties in dat zij bij de inzet van AI-systemen moeten kunnen aantonen welke *risicocategorie* van toepassing is, wie *verantwoordelijk* is voor de werking en de gevolgen van het systeem, en welke *waarborgen* er zijn ingebouwd. Het opstellen van een AI-governance-structuur, met heldere eigenaarschapsrollen, documentatievereisten en

escalatieprocedures, is daarmee niet alleen een juridische verplichting, maar ook een noodzakelijke voorwaarde voor verantwoord gebruik.

2.3 Fairness

AI-systemen leren van data, en data weer-spiegelt de wereld zoals die was, inclusief alle ongelijkheden en vooroordelen die daarin besloten liggen. Binnen de context van AI verwijst *Fairness* naar de mate waarin AI-systemen *eerlijke en onbevooroordeelde uitkomsten* produceren voor alle gebruikers en groepen.

Een centraal risico is *bias*: wanneer een AI-systeem getraind wordt op data die historische ongelijkheden of maatschappelijke vooroordelen weerspiegelt, zal het systeem deze vooroordelen reproduceren en versterken (Ferrara, 2024). Een concreet voorbeeld is de Nederlandse Toeslagenaffaire, waarbij een algoritme systematisch bepaalde groepen benadeelde. Ook genereerden AI-systemen tot voor kort bij de prompt “Genereer een afbeelding van een CEO.” overwegend beelden van blanke mannen van zekere leeftijd. Verder zijn er gevallen gedocumenteerd waarbij sollicitanten werden afgewezen op basis van naam of geslacht, uitsluitend op grond van patronen in historische trainingsdata. Kortom: bias kan overal voor problemen zorgen.

Er zijn twee dominante benaderingen om bias aan te pakken. De eerste richt zich op het corrigeren van bias vóór het trainingsproces, door de trainingsdata zelf eerlijker te maken. De tweede past correcties toe ná het genereren van een output, door de uitvoer te filteren of bij te sturen. Beide benaderingen blijken in de praktijk effectief te zijn, maar de optimale aanpak is sterk afhankelijk van de toepassing (Schwartz et al., 2022). Het advies is dan ook om een *combinatie* van beide strategieën te hanteren: investeer in de kwaliteit en representativiteit van de trainingsdata, maar implementeer ook een uitvoerlaag die de output van het systeem toetst op ongewenste ongelijkheden voordat deze aan de gebruiker worden gepresenteerd.

2.4 Transparency & Explainability

Stel dat een AI-systeem een negatieve beslissing neemt over jouw kredietaanvraag. Je wilt weten waarom dat zo is. Maar wat als het systeem dat zelf niet kan uitleggen? *Transparency & Explainability* gaat over de mate waarin mensen inzicht kunnen krijgen in hoe een AI-systeem tot een bepaalde uitkomst of beslissing is gekomen.

Naarmate AI-systemen complexer worden, neemt dit inzicht typisch af. De meest eenvoudige AI-algoritmes (zoals beslisbomen) zijn in principe volledig interpreteerbaar: elke beslissing is herleidbaar tot een expliciete, leesbare regel: als dit, dan dat. Neurale netwerken zijn al aanzienlijk minder transparant, en samen met moderne Large Language Models (LLMs) worden deze doorgaans beschouwd als zogenaamde black box modellen: de interne werking is dermate complex dat zelfs de ontwikkelaars niet precies kunnen verklaren waarom het systeem een bepaalde uitvoer genereert (Mersha et al., 2024).

Dit gebrek aan transparantie is niet alleen een technisch probleem, maar ook een juridisch en maatschappelijk vraagstuk. Het vakgebied van *Explainable AI* (XAI) probeert hierop een antwoord te formuleren. Technieken als *SHAP* (SHapley Additive exPlanations) en *LIME* (Local Interpretable Model-agnostic Explanations) reconstrueren achteraf welke inputvariabelen het zwaarst hebben gewogen bij een specifieke uitkomst. Deze technieken geven echter geen direct inzicht in de interne werking van het model, maar slechts een schatting van de bijdrage van individuele factoren. Het nog vrij jonge vakgebied *Mechanistic Interpretability* probeert hier verder aan te werken, door de informatiestroom door een model te volgen en zo te achterhalen hoe een AI-systeem daadwerkelijk tot een beslissing is gekomen.

In de praktijk is het aanbevolen bewust te kiezen voor het modeltype dat past bij de toepassing en de bijbehorende transparantievereisten. Voor toepassingen waarbij beslissingen ingrijpende gevolgen kunnen hebben voor individuen verdient een meer interpreteerbaar model de voorkeur, zelfs als dit ten koste gaat van enige nauwkeurigheid. Wanneer complexere modellen toch noodzakelijk zijn, dienen XAI-technieken structureel in het systeem te worden ingebouwd en gedocumenteerd, dus niet als een vrijblijvende toevoeging achteraf.

2.5 Human Oversight

Een AI-systeem kan veel, maar het kan ook fouten maken, zonder daar verantwoordelijkheid voor te dragen. Human Oversight betreft de mate waarin mensen betrokken blijven bij de beslissingen die AI-systemen nemen, en de verantwoordelijkheid die zij daarvoor dragen. Het kernprincipe is dat

AI-systemen, hoe geavanceerd ook, geen volledig autonome beslissingsbevoegdheid

zouden moeten hebben in situaties met significante menselijke of maatschappelijke gevolgen (Ottun & Flores, 2025). Dit principe wordt aangeduid als *human in the loop*: mensen zijn actief betrokken bij het valideren en eventueel corrigeren van de uitvoer van een AI-systeem. Een illustratief voorbeeld is de keuze tussen medisch advies van een arts versus dat van een AI-chatbot: ook al is een LLM in staat een feitelijk correct antwoord te genereren, het ontbeert de contextuele afweging, professionele verantwoordelijkheid en het oordeelsvermogen van een medisch professional.

De urgentie van menselijk toezicht neemt toe naarmate AI-systemen worden ingezet in risicovollere contexten. Denk aan geautomatiseerde selectie bij sollicitaties, of systemen die autonoom medewerkers beoordelen of ontslaan. De EU heeft dit risico erkend en Human Oversight opgenomen als een centrale vereiste in de EU AI Act. Voor hoog-risico AI-systemen gelden expliciete eisen ten aanzien van menselijk ingrijpen: systemen moeten zo ontworpen zijn dat een verantwoordelijke gebruiker de werking kan begrijpen, controleren en zo nodig onderbreken. Concreet houdt dit voor organisaties in dat zij niet alleen technische waarborgen moeten implementeren, maar ook helder moeten vastleggen wie verantwoordelijk is voor het toezicht op een AI-systeem en wanneer menselijke tussenkomst verplicht of gewenst is. De verantwoordelijkheid voor een AI-systeem kan immers niet worden gedelegeerd aan het systeem zelf.

3 Wat vinden professionals

Theorie is één ding; de praktijk is weerbarstiger. Om te onderzoeken hoe IT-professionals de afwegingen rond verantwoorde AI-inzet in de praktijk maken, voerden we een coöperatiesessie vanuit Strategy Alliance. Aan de sessie namen meerdere IT-professionals deel, elk met uiteenlopende achtergronden en ervaringen met AI-toepassingen. De sessie was gestructureerd rond een concrete casus om de discussie te verankeren in een herkenbare praktijksituatie:

Een pakketjes bezorgingsbedrijf wil graag een chatbot toevoegen aan hun website om de makkelijkste klantenvragen automatisch af te handelen. Klanten die daarmee niet geholpen kunnen worden kunnen worden doorgestuurd naar de gebruikelijke hulplijn. Ze twijfelen tussen een regel-gebaseerd systeem en een LLM.

Een regel-gebaseerd systeem zou minder dynamisch om kunnen gaan met input van gebruikers (bijvoorbeeld alleen het herkennen van de bepaalde woorden) en kan alleen vooraf gedefinieerde antwoorden geven. De garantie is wel dat deze antwoorden altijd kloppen.

Een LLM zou veel beter dynamisch om kunnen gaan met input van gebruikers en kan ook gepaste antwoorden geven op een gewenste manier voor de gebruiker. Echter kan het bedrijf met een LLM niet garanderen dat de antwoorden altijd kloppen.


3.1 Resultaten: stellingen

Deelnemers beoordeelden de keuze tussen beide systemen aan de hand van een reeks stellingen op een schaal van 1 (sterke voorkeur voor het regel-gebaseerde systeem) tot 7 (sterke voorkeur voor de LLM-oplossing). De resultaten zijn weergegeven in onderstaande figuur die de spreiding en gemiddeldes van de individuele antwoorden op de stellingen laat zien.

De resultaten laten een opvallend en consistent patroon zien. Over alle domeinvragen (Privacy & Data Protection, Accountability & Governance, Fairness, Transparency & Explainability en Human Oversight) gaven de professionals een duidelijke voorkeur voor het regel-gebaseerde systeem. De gemiddelde scores liggen allemaal tussen de 2,1 en 2,9, waarbij Human Oversight de

laagste score laat zien (gemiddelde 2,1) en Fairness de hoogste (gemiddelde 2,9). Dit is verklaarbaar: juist bij Fairness biedt een LLM potentieel voordelen, doordat het flexibeler kan reageren op uiteenlopende klantgroepen en communicatiestijlen, terwijl een regel-gebaseerd systeem voor alle gebruikers letterlijk hetzelfde antwoord geeft. Bij Human Oversight is de redenering omgekeerd: een deterministisch systeem biedt meer controle en voorspelbaarheid, wat menselijk toezicht eenvoudiger maakt.

Wat de over-all (eigen voorkeur) betreft scoorde het groep gemiddeld 2,3, wat neerkomt op een duidelijke voorkeur voor de regel-gebaseerde aanpak. Dit komt goed overeen met de individuele domeinvragen. Tegelijkertijd verwachtten de professionals dat klanten licht anders zouden oordelen: de verwachte klantvoorkeur scoorde gemiddeld 4,1, wat dichterbij het midden van de schaal zit en licht in de richting van het LLM neigt. Dit verschil weerspiegelt een reële spanning: klanten waarderen gebruiksgemak en flexibiliteit, terwijl professionals meer gewicht toekennen aan betrouwbaarheid, controleerbaarheid en juridische compliance. De spreiding in de individuele scores is bij de verwachte klantvoorkeur ook groter, wat erop wijst dat professionals onderling van mening verschillen over hoe klanten de afweging zouden maken.



3.2 Resultaten: brainstorm

Na de stellingen vroegen we de deelnemers te redeneren vanuit de rol van adviseur: welke concrete acties zou het pakketjes-bezorgingsbedrijf kunnen nemen als het toch kiest voor een LLM, om de inzet zo verantwoord mogelijk te maken? De resultaten van deze brainstorm zijn samengevat in onderstaande tabel waarin brainstormresultaten zijn geordend naar Responsible AI-domein (Ideeën zijn licht bijgesteld voor leesbaarheid, vergelijkbare resultaten zijn samengevoegd).

De aanbevelingen sluiten nauw aan bij de inzichten uit sectie 2. Opvallend is dat de deelnemers spontaan benadrukten dat het stelsel van maatregelen niet als een eenmalig project moet worden gezien, maar als een continu proces: klein beginnen, stapsgewijs uitbreiden, en voortdurend evalueren. Minstens zo opvallend is de laatste aanbeveling in de tabel: overweeg überhaupt geen LLM in te zetten voor externe klantinteractie. Dat de deelnemers deze optie ook na de brainstorm op tafel legden, onderstreept hoe serieus zij de risico's inschatten en hoe de voorkeur voor het regel-

gebaseerde systeem uit de stellingen niet alleen theoretisch is.

4 Conclusie

De centrale vraag die dit white paper beoogt te beantwoorden is niet simpelweg of organisaties AI moeten inzetten, maar hoe dat op een verantwoorde manier kan. Het antwoord is dat verantwoorde AI-inzet geen eenmalige technische keuze is, maar een doorlopend proces dat vraagt om aandacht voor vijf samenhangende domeinen: Privacy & Data Protection, Accountability & Governance, Fairness, Transparency & Explainability en Human Oversight. Elk domein brengt eigen risico's met zich mee en vraagt om specifieke waarborgen. Tegelijk versterken de domeinen elkaar. Een systeem dat transparant is, is ook beter te controleren. Een systeem waarvoor governance goed is ingericht, maakt verantwoorde datakeuzes gemakkelijker.

De resultaten van de coöperatiesessie bevestigen dit beeld. IT-professionals geven, als zij de keuze moeten maken tussen een regel-

<i>Responsible AI-domein</i>	<i>Concrete aanbevelingen</i>
Privacy & Data Protection	• Klantgegevens direct na afhandeling verwijderen • Zo specifiek mogelijke, geverifieerde dataset gebruiken • Input- en outputfilters inrichten (guards) • Prompts transparant labelen voor mogelijke trainingsdoeleinden
Accountability & Governance	• Procedure vastleggen voor het doorvoeren van aanpassingen aan het systeem • Grenzen van het systeem expliciet afbakenen • Verantwoordelijkheid voor de output formeel beleggen • Proactief uitleg geven over de werking, ook wanneer het systeem tekortschiet • Doelstellingen en kernwaarden koppelen aan de EU AI Act • De AI Act direct toepassen, niet afwachten
Fairness	• Klanttesten uitvoeren om bias in antwoorden te detecteren • Sturen op eerlijke en evenwichtige antwoorden
Transparency & Explainability	• Contextbegrenzungen van het systeem expliciet communiceren naar gebruikers
Human Oversight	• Human-in-the-loop structureel inrichten • Bepaalde vragen direct doorsturen naar een menselijke medewerker • Focussen op lange termijn klanttevredenheid, niet alleen technische correctheid
Algemeen	• Klein beginnen: eenvoudig opstarten en stapsgewijs uitbreiden • Scherp formuleren wat de werkelijke behoefte is vóór implementatie • Overwegen geen LLM in te zetten voor externe klantinteractie

gebaseerd systeem en een LLM voor een klantgerichte chatbot, duidelijk de voorkeur aan het regel-gebaseerde systeem (gemiddelde score 2,3 op een schaal van 1 tot 7). Die voorkeur is niet ingegeven door onbekendheid met LLMs, maar door een bewuste afweging: betrouwbaarheid, controleerbaarheid en juridische compliance wegen zwaar als het gaat om systemen die direct met klanten communiceren. Tegelijkertijd erkennen de professionals dat klanten de balans anders kunnen leggen (verwachte klantvoorkeur: gemiddeld 4,1), wat vraagt om een zorgvuldige communicatiestrategie over de mogelijkheden én de beperkingen van het gekozen systeem.

De brainstorm leidde tot een reeks concrete aanbevelingen die samen een praktisch kompas vormen voor organisaties die AI willen inzetten. De rode draad: begin klein, wees scherp over wat je werkelijk nodig hebt, leg verantwoordelijkheden expliciet vast, en zorg dat menselijk toezicht structureel is verankerd in de werkwijze. Niet als sluitpost, maar als onderdeel van het ontwerp. Daarmee sluit de praktijk naadloos aan op de theorie: verantwoorde AI begint niet bij de technologie, maar bij de vraag wat je ermee wilt bereiken en welke verantwoordelijkheid je daarbij bereid bent te dragen.

References

Barredo Arrieta, A., Díaz-Rodríguez, N., Del Ser, J., Bannet, A., Tabik, S., Barbado, A., Garcia, S., Gil-Lopez, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2020). Explainable artificial intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58, 82–115.

Dignum, V. (2019). *Responsible artificial intelligence. how to develop and use AI in a responsible way*. Springer Nature.

European Commission, Directorate-General for Communications Networks, Content and Technology, & High-Level Expert Group on Artificial Intelligence. (2019). *Ethics guidelines for trustworthy AI* (tech. rep.). Publications Office of the European Union.

Regulation (EU) 2024/1689 of the European Parliament and of the Council laying down harmonised rules on Artificial Intelligence (Artificial Intelligence Act) (2024).

Ferrara, E. (2024). Fairness and bias in artificial intelligence: A brief survey of sources, impacts,

and mitigation strategies. *Sci*, 6 (1), 3.

Guizzardi, G. (2024). The two cultures of AI. <https://utwente.yuja.com/V/Video?v=741907&node=3642861&a=211232278>

Gulyamov, S., Gulyamov, S., Rodionov, A., Khursanov, R., Mekhmonov, K., Babaev, D., & Rakhimjonov, A. (2026). Prompt injection attacks in large language models and ai agent systems: A comprehensive review of vulnerabilities, attack vectors, and defense mechanisms. *Information*, 17 (1), 54.

Lee, R. W., Jun, T. J., Lee, J.-M., Cho, S. I., Park, H. J., & Suh, J. (2025). Vulnerability of large language models to prompt injection when providing medical advice. *JAMA Network Open*, 8 (12).

Liu, Z., & Zheng, Y. (2022). *AI ethics and governance. black mirror and order*. Springer Nature.

Mersha, M., Lam, K., Wood, J., AlShami, A. K., & Kalita, J. (2024). Explainable artificial intelligence: A survey of needs, techniques, applications, and future direction. *Neurocomputing*, 599, 128111.

Ottun, A.-R. O., & Flores, H. (2025). *Trustworthy ai in practice: A comprehensive review of human oversight and human-in-the-loop approaches*.

Piaget, J. (2005). *The psychology of intelligence*. Routledge.

Radanliev, P. (2025). AI ethics: Integrating transparency, fairness, and privacy in ai development. *Applied Artificial Intelligence*, 39 (1).

Schwartz, R., Vassilev, A., Greene, K. K., Perine, L., Burt, A., & Hall, P. (2022, March). *Towards a standard for identifying and managing bias in artificial intelligence*.